Universidad Digital de Antioquia

Ingeniería de Desarrollo de Software y Datos

Qué influye en la interacción de las publicaciones de TikTok:

proyecto de analítica descriptiva con el dataset TikTok Videos (5.6B)

Avance AE2 – Ideación, diseño y documentación de la necesidad (Etapa 1)

Integrantes: Santiago Ramírez Vásquez, Santiago Jimenez Otalvaro

Grupo: AE_Grupo 9

Asignatura: Analítica de Datos

Docente: Andrés Felipe Callejas

22 de octubre de 2026

Tabla de contenido

Índice de tablas

Nota: en esta entrega no se incluyen gráficas ni ilustraciones; por eso no se presentan índices de figuras.

1. Introducción

Las plataformas de video corto generan enormes volúmenes de publicaciones con métricas públicas de alcance e interacción: vistas, “me gusta”, comentarios, compartidos y guardados. Antes de plantear cualquier análisis es necesario conocer bien los datos disponibles: qué representa cada registro, de dónde provienen y qué límites tienen.

Este proyecto utiliza el dataset TikTok Videos (5.6 billion), publicado en Hugging Face como datasocial/tiktok-5.6B-videos. Según su ficha, contiene 5.598.141.717 filas y ocupa 460 GB, con una fila por publicación (video o foto) y columnas sobre su formato, contenido, características comerciales y métricas de interacción.

Por su tamaño, el dataset no puede cargarse completo en un equipo personal; por eso se trabaja con una muestra, cuya construcción y limitaciones se documentan en este informe. El propósito de esta primera etapa es documentar la necesidad de información, seleccionar y reconocer el dataset, definir el diseño inicial del análisis y verificar con un notebook de Jupyter que los datos pueden cargarse en un DataFrame de Pandas y resumirse automáticamente en un archivo de texto.

2. Planteamiento de la necesidad

2.1 Escenario y beneficiario

Escenario hipotético. Se supone el equipo de contenidos de una agencia de comunicación que gestiona cuentas de marcas en TikTok y quiere orientar sus decisiones de producción: qué tipo de publicación, de qué duración y en qué formato comercial conviene priorizar. El escenario es propuesto con fines académicos; no corresponde a una agencia real ni a un problema observado y comprobado.

2.2 Información requerida

Se necesita conocer cómo se comportan las vistas y la tasa de interacción de las publicaciones según su tipo (video o foto), su rango de duración, su país y si corresponden a publicidad o a contenido de TikTok Shop. Esta información serviría para describir qué características se asocian con mayor o menor alcance e interacción y para decidir en qué aspectos profundizar en etapas posteriores.

Se trata de una necesidad propuesta: no se afirma que exista un problema comprobado, sino que falta una descripción ordenada de los datos que permita formular hipótesis posteriores.

2.3 Pregunta de análisis

¿Cómo varían las vistas medianas y la tasa de interacción de las publicaciones de la muestra según su tipo (video o foto), rango de duración, país y si son publicidad o contenido de TikTok Shop?

3. Justificación

Una descripción clara de cómo se distribuyen el alcance y la interacción entre tipos de publicación permite priorizar preguntas y evita iniciar análisis más complejos sin conocer la estructura de los datos. La analítica descriptiva es, además, el punto de partida natural de otros tipos de análisis (Tableau, s. f.; TechTarget, s. f.).

El dataset es adecuado para esta necesidad por las siguientes razones, verificables en su ficha y en el notebook:

- Incluye, para cada publicación, vistas, “me gusta”, comentarios, compartidos y guardados, además de una tasa de interacción calculada.
- Incluye variables para formar grupos: tipo de publicación, duración, país, idioma, indicadores de publicidad (is_ad), de TikTok Shop (is_shop_video) y de contenido de marca (branded_content).
- Está en formato Parquet, compatible con Pandas, y permite leer una parte sin descargar todo el archivo.
- Su licencia es CC BY-NC 4.0, que permite uso de investigación y personal no comercial, condición que cumple este trabajo académico.
-

4. Objetivos

4.1 Objetivo general

Caracterizar y comparar, mediante analítica descriptiva, las vistas y la tasa de interacción de las publicaciones de una muestra del dataset TikTok Videos (5.6B) según su tipo, duración, país y carácter comercial.

4.2 Objetivos específicos

1. Obtener una muestra del dataset desde Hugging Face, cargarla en un DataFrame y documentar la ficha del dataset y la forma de selección de la muestra.
2. Reconocer la estructura de los datos: cantidad de registros y columnas, tipos de dato y valores nulos o vacíos, con un resumen generado automáticamente en un archivo .txt.
3. Construir un diccionario inicial de las variables relevantes, declarando como pendiente lo que la documentación no define.
4. Definir el alcance, las limitaciones y el diseño inicial del análisis de acuerdo con la pregunta planteada.

5. Marco teórico inicial

5.1 Analítica descriptiva

La analítica descriptiva es un tipo de analítica de datos que examina datos pasados para dar cuenta de lo que ha ocurrido, y se considera la más simple de las cuatro categorías generalmente aceptadas: descriptiva, diagnóstica, predictiva y prescriptiva (TechTarget, s. f.). No pretende explicar por qué ocurre algo; esa tarea corresponde a la analítica diagnóstica (RudderStack, s. f.). Utiliza datos históricos para identificar patrones, tendencias y relaciones y para generar reportes (Tableau, s. f.).

5.2 Variables numéricas y categóricas, y medidas de resumen

Las variables numéricas (vistas, duración) se resumen con medidas como mediana, cuartiles, mínimo y máximo; las categóricas (tipo, país) con frecuencias y proporciones. Las métricas de redes sociales suelen concentrarse en pocos registros con valores muy altos, por lo que la mediana describe mejor un caso típico que el promedio.

5.3 Conceptos del dominio

- **Tasa de interacción (engagement_rate):** según la ficha, (me gusta + comentarios + compartidos + guardados) / vistas.
- **Publicación de tipo video o foto:** la variable type distingue ambos formatos; en las fotos la duración es 0 según la ficha.

- **Publicidad y contenido comercial:** is_ad indica Spark Ads; branded_content puede ser paid_partnership, shop_affiliate o vacío; is_shop_video y product_id/seller_id se refieren a TikTok Shop.
- **Página Para Ti (For You):** not_recommended_for_fyp indica que TikTok mantiene la publicación fuera de esa página de recomendación.

6. Metodología de la etapa 1

6.1 Selección y ficha del dataset

El dataset se eligió por tener estructura tabular, variables de interacción y de formato, licencia explícita y formato Parquet que permite leer solo una parte. La Tabla 1 resume su ficha.

Tabla . Ficha del dataset

Campo	Valor
Nombre	TikTok Videos (5.6 billion)
Identificador del repositorio	datasocial/tiktok-5.6B-videos
Enlace directo	https://huggingface.co/datasets/datasocial/tiktok-5.6B-videos
Fecha de consulta	22 de octubre de 2026
Formato y tamaño	Parquet; 5.598.141.717 filas; 460 GB (según la ficha)
Subset / split	default / train (único)
Revisión (commit)	a466d03349b4afa490ac8906c8b5d17f6006abc0
Licencia	CC BY-NC 4.0 (investigación y uso personal; el uso comercial requiere otro acuerdo)
Procedencia (según la ficha)	Recolección con la API móvil de TikTok; la ficha enlaza el código del recolector. Los videos antiguos provienen de un archivo.
¿Datos sintéticos?	No se declaran como sintéticos
¿Se usa una muestra?	Sí (ver 6.2)

Fuente: elaboración propia a partir de la ficha en Hugging Face.

6.2 Muestra utilizada

El dataset completo no cabe en un equipo personal, por lo que se trabaja con una muestra de hasta 200.000 filas. Para construirla, el notebook elige al azar (semilla 42) un archivo Parquet del repositorio y lee cinco grupos de filas repartidos a lo largo de ese archivo, tomando hasta 40.000 filas de cada uno. Se cargan 27 de las 31 columnas: no se cargan caption, mentions, on_screen_text ni hashtag_ids, porque contienen texto libre o identificadores de creadores y no son necesarias para la pregunta.

Esta muestra no es aleatoria simple sobre las 5.598 millones de filas: representa el periodo y los tipos de publicación que contenga el archivo elegido. Su tamaño exacto, el periodo cubierto y la fracción respecto al total se confirman en el notebook y quedan registrados en el archivo resumen_dataframe.txt. Filas: 200,000 | Columnas: 27 Fracción del dataset completo: 0.003573%. Si el método de lectura por archivos fallara, el notebook usa las primeras filas por streaming, que corresponden a videos de 2014 y generan un sesgo temporal fuerte; en ese caso debe declararse.

6.3 Unidad de análisis

Cada fila representa una publicación de TikTok (video o foto), con una fotografía de sus métricas en la fecha stats_updated_at. La cobertura del dataset respecto al total de publicaciones de TikTok no está definida en la ficha consultada y queda pendiente de verificar.

6.4 Diccionario inicial de variables

La Tabla 2 presenta las variables que se cargan en la muestra. Los significados provienen de la ficha del dataset; lo que la ficha no define se marca como pendiente de verificar. Los tipos son los publicados en la ficha y se confirman en el notebook.

Tabla . Diccionario inicial de variables

Variable	Significado	Tipo de dato	Unidad / observación
video_id	Identificador de la publicación.	UInt64	Sin unidad
posted_at	Fecha y hora de publicación.	Fecha-hora	UTC
country	Región que TikTok asigna a la publicación.	Texto	Puede venir vacío
language	Idioma asignado por TikTok.	Texto	“un” = indeterminado

Variable	Significado	Tipo de dato	Unidad / observación
type	Tipo de publicación: video o photo.	Texto	—
duration_ms	Duración de la publicación.	UInt32	Milisegundos; 0 en fotos; videos antiguos redondeados al segundo
image_count	Cantidad de imágenes (publicaciones de fotos).	UInt8	Imágenes
width, height	Dimensiones de la publicación.	UInt16	Píxeles; 0 en registros antiguos
hashtags	Hashtags de la publicación, en minúsculas.	Lista de texto	Puede ser lista vacía
sound_id	Identificador del sonido usado.	UInt64	0 = ninguno
is_ad	Indica si es publicidad (Spark Ads).	UInt8 (0/1)	—
branded_content	Contenido de marca: paid_partnership, shop_affiliate o vacío.	Texto	—
product_id, seller_id	Producto y vendedor de TikTok Shop.	UInt64	0 = ninguno
is_shop_video	Indica si es un video de TikTok Shop.	UInt8 (0/1)	—
is_ai_generated	Indica si es contenido generado con IA.	UInt8 con nulos	Nulo = TikTok no lo indicó
not_recommended_for_fyp	Indica si TikTok la mantiene fuera de la página Para Ti.	UInt8 con nulos	—
sound_muted	Audio retirado por derechos de autor.	UInt8 (0/1)	—
views, likes, comments, shares, saves, downloads	Vistas, me gusta, comentarios, compartidos, guardados y descargas.	UInt64	Conteos al momento de stats_updated_at; downloads puede ser 0 o nulo en registros antiguos
engagement_rate	(likes + comments + shares + saves) / views.	Float32 con nulos	Proporción (0 a 1 aprox.)

Variable	Significado	Tipo de dato	Unidad / observación
stats_updated_at	Fecha de actualización de las métricas.	Fecha-hora	UTC; varía entre registros

Fuente: elaboración propia con base en la ficha del dataset en Hugging Face.

6.5 Alcance y limitaciones

- **Unidad y cobertura:** publicaciones de TikTok incluidas en una muestra del dataset; cobertura respecto a toda la plataforma pendiente de verificar.
- **Variables utilizadas:** views, engagement_rate, type, duration_ms, country, is_ad, is_shop_video, branded_content y posted_at; las demás se usan para reconocer los datos.
- **Muestra:** no es aleatoria simple del dataset completo y sus resultados no se extrapolan a toda la plataforma.
- **Métricas en fechas distintas:** cada registro tiene su propio stats_updated_at; publicaciones con más tiempo en línea pueden acumular más vistas.
- **Registros antiguos:** provienen de un archivo, con campos en 0 o nulos y duración redondeada, según la ficha.
- **Etiquetas de TikTok:** country y language son asignados por TikTok y pueden estar vacíos o ser “un”.
- **Distribuciones muy sesgadas:** por eso se priorizan medianas y cuartiles sobre promedios.
- **Sin causalidad:** las comparaciones son descriptivas y no permiten afirmar que una característica cause más interacción.
- **Ética y privacidad:** la ficha indica que los datos se recolectaron con la API móvil de TikTok; las condiciones de uso de la plataforma deben revisarse. Se excluyen textos libres e identificadores de creadores, se reportan solo resultados agregados y se respeta la licencia no comercial.

6.6 Diseño inicial del análisis

La Tabla 3 relaciona cada paso previsto con las variables que utiliza y el resultado que se espera describir, de modo que todos respondan a la pregunta de análisis.

Tabla . Diseño inicial del análisis

N.º	Paso previsto	Variables	Resultado esperado
1	Cargar la muestra y revisar estructura, tipos, nulos y vacíos.	Todas	Dimensiones, tipos y conteo de nulos y vacíos.

N.º	Paso previsto	Variables	Resultado esperado
2	Definir el tratamiento de nulos, ceros con significado (“ninguno”) y registros antiguos.	is_ai_generated, sound_id, duration_ms, engagement_rate	Criterios documentados y reproducibles.
3	Describir la distribución de vistas y de la tasa de interacción.	views, engagement_rate	Mediana, cuartiles, mínimo y máximo.
4	Comparar por tipo de publicación y rango de duración.	type, duration_ms	Mediana de vistas e interacción por grupo.
5	Comparar por país y por carácter comercial.	country, is_ad, is_shop_video, branded_content	Mediana de vistas e interacción por grupo.
6	Presentar resultados en tablas y gráficas de barras.	Las anteriores	Respuesta descriptiva a la pregunta de análisis.

Fuente: elaboración propia.

7. Reconocimiento del dataset

El notebook AE2_Exploracion_Dataset.ipynb obtiene la muestra desde Hugging Face, la carga en un DataFrame de Pandas y muestra los primeros registros, las dimensiones, los nombres y tipos de columnas y los valores nulos por columna, además del conteo de valores vacíos. Con el mismo DataFrame genera automáticamente el archivo resultados/resumen_dataframe.txt (UTF-8), que incluye el identificador, el split, la descripción de la muestra, las dimensiones, las columnas con sus tipos y los nulos.

De acuerdo con la ficha, el dataset reúne una variable de resultado (views y engagement_rate), variables categóricas que definen grupos (type, country, language, is_ad, is_shop_video, branded_content) y variables numéricas para describir la distribución dentro de cada grupo (duration_ms, likes, comments, shares, saves). Con ellas es posible calcular medianas y cuartiles por grupo, que es lo que exige la pregunta de análisis.

Referencias

datasocial. (s. f.). *TikTok Videos (5.6 billion)*. Hugging Face. Consultado el 22 de octubre de 2026. https://huggingface.co/datasets/datasocial/tiktok-5.6B-videos

TechTarget. (s. f.). *What is descriptive analytics?* Consultado el 22 de octubre de 2026. https://www.techtarget.com/whatis/definition/descriptive-analytics

Tableau. (s. f.). *What is descriptive analytics?* Consultado el 22 de octubre de 2026. https://www.tableau.com/analytics/what-is-descriptive-analytics

RudderStack. (s. f.). *What is descriptive analytics? Definition, benefits, and examples*. Consultado el 22 de octubre de 2026. https://rudderstack.com/learn/data-analytics/what-is-descriptive-analytics